

Informe del Compilador HULK

David Sánchez

July 3, 2025

Abstract

Este documento presenta un informe técnico sobre el diseño e implementación de un compilador para el lenguaje de programación HULK. Se detallan las fases clave del proceso de compilación, incluyendo el análisis léxico, sintáctico y semántico, así como la generación de código intermedio y su ejecución mediante un intérprete JIT (Just-In-Time) basado en LLVM. El objetivo principal es proporcionar una visión clara de la arquitectura del compilador, las decisiones de diseño tomadas y las herramientas utilizadas en su desarrollo.

Contents

1 Introducción

Este informe presenta una propuesta de compilador para el lenguaje de programación HULK. Está organizado de la siguiente manera: las secciones 2, 3 y 4 describen los análisis léxico, sintáctico y semántico, respectivamente. La sección 5 detalla el proceso de generación de código.

2 Análisis Léxico

2.1 Tokens

El analizador léxico se encarga de leer el código fuente y agruparlo en una secuencia de tokens. Los tokens representan las unidades mínimas con significado del lenguaje, como palabras clave ('if', 'else', 'while'), identificadores, números, cadenas y operadores, y para manipularlos fue creada la clase *Token*, que además almacena información adicional como la posición en el código fuente.

2.2 Expresiones Regulares

Cada tipo de token se define mediante una expresión regular que describe el patrón de caracteres que lo conforma. Por ejemplo, un identificador de variable está definido con la expresión regular `[a-z] [`

`a-zA-Z0-9]*`, indicando que puede ser cualquier combinación de letras mayúsculas, minúsculas y números, siempre que em

2.3 Implementación con Flex

Para el análisis léxico, el compilador utiliza Flex, un generador de analizadores léxicos rápido. Las definiciones de los tokens, basadas en expresiones regulares, se especifican en el fichero `lexer.l`. Flex genera automáticamente el código C para un lexer eficiente que procesa el código fuente y produce una secuencia de tokens. Estos tokens son consumidos por el analizador sintáctico generado por Bison.

3 Análisis Sintáctico

3.1 Gramática

La estructura sintáctica del lenguaje HULK se define mediante una gramática libre de contexto, presentada en formato BNF (Backus-Naur Form). Esta gramática especifica cómo se pueden combinar los tokens para formar construcciones válidas como expresiones, declaraciones y sentencias. La gramática completa se encuentra en el apéndice de este informe.

3.2 Tipo de Parser

Se utilizó un parser de tipo LALR(1) (Look-Ahead LR), generado por Bison. Este tipo de parser es potente y eficiente, capaz de analizar una amplia clase de gramáticas libres de contexto, siendo el estándar en muchas herramientas de compilación.

3.3 Árbol de Sintaxis Abstracta (AST)

El resultado del análisis sintáctico es un Árbol de Sintaxis Abstracta (AST). El AST es una representación jerárquica del código fuente que captura su estructura esencial, eliminando detalles sintácticos irrelevantes como paréntesis o puntos y comas. Este árbol es la estructura de datos principal que se utiliza en las fases posteriores del compilador.

3.4 Implementación con Bison

Para el análisis sintáctico, se ha empleado Bison, un generador de parsers. La gramática del lenguaje HULK, junto con las acciones semánticas, se define en el fichero `parser.y`. Bison procesa este fichero para generar un parser LALR(1) en C++. Las acciones semánticas, escritas en C++, se encargan de construir el Árbol de Sintaxis Abstracta (AST) a medida que el parser reconoce las estructuras sintácticas. Este enfoque modular, combinado con Flex, facilita el mantenimiento y la escalabilidad del compilador.

4 Análisis Semántico

El chequeo semántico se realiza en tres fases principales, cada una implementada por un visitante (visitor) especializado que recorre el AST. Se utiliza un contexto global para almacenar información sobre tipos, variables y funciones.

4.1 Type Collector

Este visitor se encarga de recolectar las definiciones de tipos en el programa.

- **Lógica:** Recorre el AST y registra los tipos definidos por el usuario (clases, protocolos, etc.) en el contexto global.
- **Propósito:** Garantizar que todos los tipos estén definidos antes de ser utilizados.

4.2 Symbol Collector

Este visitor recolecta las definiciones de variables y funciones.

- **Lógica:** Recorre el AST y registra las variables, funciones y métodos en el contexto correspondiente.
- **Propósito:** Construir las tablas de símbolos para cada ámbito (global, local, de clase) y verificar que no haya redefiniciones.

4.3 Semantic Checker

Este visitor realiza el análisis semántico detallado.

- **Lógica:** Verifica que las operaciones sean válidas según los tipos de datos, que las variables estén declaradas antes de ser usadas y que las funciones sean llamadas con los argumentos correctos.
- **Propósito:** Detectar errores semánticos como tipos incompatibles, uso de variables no declaradas o violaciones de las reglas del lenguaje.

4.4 Contexto y Búsqueda Recursiva

El contexto es una estructura central que almacena la información semántica. Cuando se busca una variable, función o tipo, el contexto realiza una búsqueda recursiva desde el ámbito actual hacia los ámbitos superiores, manejando correctamente los ámbitos anidados y la herencia.

5 Generación de Código

El generador de código está basado en un patrón visitor que recorre el AST y traduce cada nodo a instrucciones de bajo nivel utilizando la infraestructura de LLVM.

5.1 Representación Intermedia (LLVM IR)

Se utiliza LLVM Intermediate Representation (IR) como código intermedio. LLVM IR es un lenguaje de ensamblador de bajo nivel con un formato de tres direcciones (Three-Address Code), lo que permite que el código generado sea portable y susceptible a múltiples optimizaciones.

5.2 Visitor de Generación de Código

El visitor de generación de código implementa métodos para cada tipo de nodo del AST. Su función es transformar las construcciones del lenguaje HULK en instrucciones de LLVM IR.

- Gestiona la correspondencia entre variables del código fuente y sus representaciones en LLVM.
- Genera la declaración de funciones, la reserva de memoria para variables y los bloques básicos para estructuras de control (condicionales, bucles).

5.3 Intérprete JIT (Just-In-Time)

Una vez generado el código LLVM IR, el compilador utiliza el intérprete JIT de LLVM para ejecutar el programa directamente en memoria, sin necesidad de compilar a un binario nativo. El JIT traduce dinámicamente el IR a código máquina para la plataforma actual y lo ejecuta, facilitando las pruebas y el desarrollo interactivo.

6 Pruebas

7 Implementaciones Propias Anteriores

En las fases iniciales del proyecto, se desarrollaron componentes a medida para el análisis léxico y sintáctico. Aunque finalmente se optó por las herramientas estándar Flex y Bison por su robustez y eficiencia, estas implementaciones propias sirvieron como una valiosa prueba de concepto y un profundo ejercicio de aprendizaje.

7.1 Lexer Personalizado

Se implementó un analizador léxico manual en C++. Este lexer utilizaba una tabla de especificaciones de tokens definida programáticamente en 'hulkGrammar.hpp', que asociaba nombres de tokens con sus correspondientes expresiones regulares. El lexer procesaba el código fuente y, utilizando estas definiciones, generaba una secuencia de tokens para el analizador sintáctico. Este enfoque ofrecía un control granular sobre el proceso de tokenización y facilitaba la integración con el resto del compilador.

7.2 Parser SLR(1) Personalizado

Paralelamente, se desarrolló un parser SLR(1) a medida. La clase 'SLR1Parser' era la encargada de tomar una gramática definida en C++ (también en 'hulkGrammar.hpp'), construir las tablas de parseo SLR(1) (acción y goto) en tiempo de ejecución, y luego utilizar estas tablas para analizar la secuencia de tokens. Las acciones semánticas, responsables de construir el AST, se implementaron como funciones lambda asociadas a cada producción. Este diseño permitía una integración estrecha y un control total sobre el proceso de parsing.

A Gramática Completa

```
input -> line
      | lines_block

lines_block -> { lines }

lines -> epsilon
      | non_empty_lines

non_empty_lines -> line
                | non_empty_lines line

line -> expr ;
      | func_asign ;
      | type_node_decl

expr -> arit_op
      | bool_expr
      | while_expr
      | string
      | id_expr
      | func_call
```

```

| let_assign
| if conditional
| member_access_expr
| expr := expr
| expr = expr
| expr @ expr
| expr @@ expr

func_assign -> function ID ( args_list ) => expr
| function ID ( args_list ) : ID => expr
| function ID ( args_list ) { lines }
| function ID ( args_list ) : ID { lines }

args_list -> epsilon
| id_expr
| args_list , id_expr

id_expr -> ID : ID
| ID

let_assign -> let var_assign_list in expr
| let var_assign_list in lines_block

var_assign_list -> id_expr = expr
| id_expr = expr as ID
| id_expr = new_expr
| var_assign_list , id_expr = expr
| var_assign_list , id_expr = expr as ID
| var_assign_list , id_expr = new_expr

new_expr -> new ID ( expr_list )

expr_list -> epsilon
| expr
| new_expr
| expr_list , expr
| expr_list , new_expr

func_call -> ID ( expr_list )

arit_op -> number
| ( expr )
| expr + expr
| expr - expr
| expr * expr
| expr / expr
| expr ^ expr
| - expr

bool_expr -> boolean
| expr >= expr
| expr > expr
| expr <= expr
| expr < expr
| expr == expr
| expr != expr
| expr & expr
| expr | expr

```

```

| ! expr
| id_expr is ID
| func_call is ID

conditional -> ( bool_expr ) expr else expr
| ( bool_expr ) lines_block else expr
| ( bool_expr ) expr else lines_block
| ( bool_expr ) lines_block else lines_block
| ( bool_expr ) expr elif conditional
| ( bool_expr ) lines_block elif conditional

while_expr -> while ( bool_expr ) lines_block
| while ( bool_expr ) expr

type_node_decl -> type ID { type_body_elements }
| type ID inherits ID { type_body_elements }
| type ID inherits ID ( args_list ) { type_body_elements }
| type ID ( args_list ) { type_body_elements }
| type ID ( args_list ) inherits ID { type_body_elements }
| type ID ( args_list ) inherits ID ( args_list ) { type_body_elements }

type_body_elements -> epsilon
| type_body_elements attribute
| type_body_elements method

attribute -> id_expr = expr ;
| id_expr = expr as ID ;

method -> ID ( args_list ) => expr ;
| ID ( args_list ) : ID => expr ;
| ID ( args_list ) { lines }
| ID ( args_list ) : ID { lines }

member_access_expr -> expr . ID
| expr . func_call

```